Universidad Nacional de Educación a Distancia
(UNED)

Máster Universitario en Investigación en Inteligencia
Artificial

FUNDAMENTOS DEL PROCESAMIENTO LINGÜÍSTICO

Tarea 2: Diseño y Validación de un Extractor de Proposiciones Semánticas mediante Stanford CoreNLP

Autor:

Fernando Domingo Martínez Marco

Asignatura:

Fundamentos del Procesamiento Lingüístico

Curso Académico 2025/2026

21 de enero de 2026

Índice

1. Introducción **2**
1.1. El Análisis Sintáctico en el Procesamiento Digital 2
1.2. Enfoques: Dependencias frente a Constituyentes 2
1.3. Importancia de la Lematización y el POS Tagging 2
1.4. El Contexto Literario de Sherlock Holmes 2

2. Configuración Tecnológica y Pipeline **2**
2.1. Stanford CoreNLP v4.5.4 2
2.2. Implementación en Python: CoreNLPClient 2
2.3. Infraestructura y Recursos Hardware 3

3. Diseño del Algoritmo de Extracción **3**
3.1. Navegación del Grafo (`extractor.py`) 3
3.2. Técnicas de Navegación en grafos de Dependencias 3
3.3. Uso de Enhanced++ Dependencies 4
3.4. Jerarquía de Exclusión de Patrones 4

4. Tratamiento Avanzado y Mejoras Semánticas **4**
4.1. Normalización de la Voz Pasiva (Punto Extra) 4
4.2. Unificación de Entidades y Personajes (NER) 4
4.3. Detección Multidimensional: POS y NER 4
4.4. Gestión de Phrasal Verbs 5

5. Análisis de Resultados en el Corpus **5**
5.1. Impacto de la Unificación NER en el Ranking 5

6. Traza de Procesamiento Algorítmico **6**

7. Problemas Encontrados y Soluciones **6**

8. Manual de Ejecución e Instalación **6**

9. Trabajo Futuro y Evolución **6**

10. Conclusiones Finales **6**

A. Muestreo Detallado de Salida JSON **7**

B. Mapeo de Etiquetas POS Utilizadas **7**

C. Glosario Lingüístico y Referencias **7**
C.1. Glosario 7
C.2. Referencias Bibliográficas 7

1. Introducción

El análisis sintáctico constituye uno de los pilares del Procesamiento del Lenguaje Natural (PLN). Su objetivo es identificar las relaciones lógicas entre las palabras para comprender quién realiza una acción, sobre qué recae y bajo qué circunstancias. En esta práctica, se ha desarrollado un pipeline de extracción de proposiciones estructuradas bajo el esquema **Sujeto-Verbo-Objeto (NVN)** y sus variantes, utilizando para ello el motor de **Stanford CoreNLP**.

1.1. El Análisis Sintáctico en el Procesamiento Digital

La superficie gramatical de un texto (las palabras escritas) es solo una representación de una idea subyacente. El análisis sintáctico permite a las máquinas pasar de procesar çadenas de texto.ª procesar .ªestructuras de conocimiento". Este informe detalla el proceso de transformar prosa narrativa en un grafo estructurado mediante técnicas de parsing de dependencias.

1.2. Enfoques: Dependencias frente a Constituyentes

Mientras que el análisis de constitutuyentes se centra en la jerarquía de grupos (Sintagma Nominal, etc.), el análisis de dependencias establece arcos directos entre palabras. Este enfoque es el estándar en tareas de extracción por su correspondencia con los roles semánticos de **Universal Dependencies (UD)**.

1.3. Importancia de la Lematización y el POS Tagging

Antes de entender la relación entre palabras, el sistema debe saber qué categoría gramatical tiene cada una (**POS Tagging**) y cuál es su forma léxica (**Lematización**). Sin estos pasos, el extractor no podría identificar que "vieronz "ver"pertenecen a la misma acción semántica.

1.4. El Contexto Literario de Sherlock Holmes

El corpus seleccionado (*Sherlock Holmes*) aporta desafíos adicionales por su estilo del siglo XIX. El uso de modismos y una sintaxis a veces compleja pone a prueba la flexibilidad de los modelos neuronales de Stanford, requiriendo un ajuste fino del pipeline de anotación.

2. Configuración Tecnológica y Pipeline

2.1. Stanford CoreNLP v4.5.4

Se ha seleccionado este motor por su robustez en lengua inglesa. Para gestionar el volumen del corpus completo, el sistema opera bajo una arquitectura **Cliente-Servidor**, cargando los modelos en la JVM una única vez.

2.2. Implementación en Python: CoreNLPClient

Siguiendo las instrucciones del equipo docente, la integración se ha realizado mediante la clase `CoreNLPClient` de la librería `stanza`. Es fundamental recalcar que **no se utilizan las pipelines nativas de Stanza**, sino que Stanza se emplea exclusivamente como un cliente ligero para realizar peticiones al servidor Java de Stanford, garantizando así un rendimiento óptimo y el uso de los modelos oficiales de CoreNLP.

2.3. Infraestructura y Recursos Hardware

Debido a la profundidad del análisis (Dependencias Mejoradas + NER), el servidor CoreNLP requiere una configuración estable. De acuerdo con las instrucciones, se ha asignado un límite de **3GB de RAM** mediante la bandera `-mx3g`. El servidor escucha en el puerto 9005.

3. Diseño del Algoritmo de Extracción

3.1. Navegación del Grafo (`extractor.py`)

El algoritmo navega dinámicamente por el grafo **Enhanced++ Dependencies**. Este grafo es superior al básico porque hace explícitos elementos implícitos, como los agentes en estructuras pasivas.

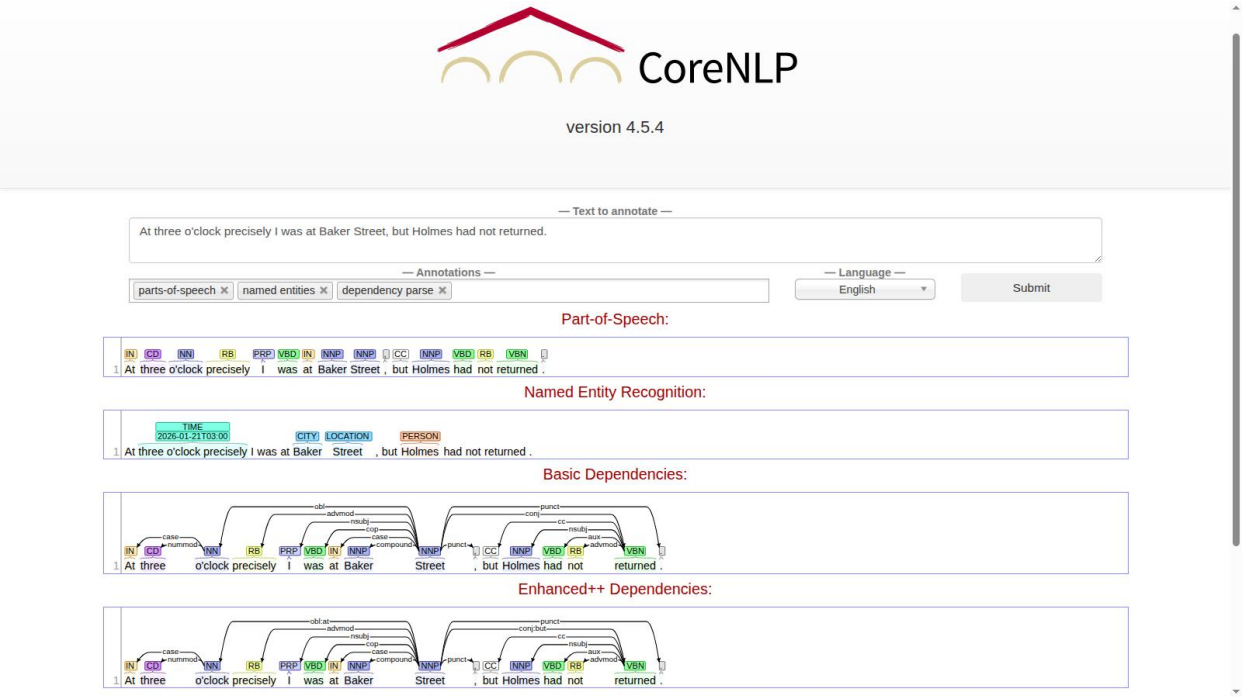

Figura 1: Trazado del análisis multinivel de CoreNLP sobre una frase original del libro.

3.2. Técnicas de Navegación en grafos de Dependencias

La extracción no se realiza mediante expresiones regulares sobre el texto, sino mediante algoritmos de búsqueda en profundidad (DFS) limitados sobre el grafo de dependencias. Se han definido funciones de búsqueda que para cada nodo verbal localizan:

- **Sujetos**: Priorizando `nsubj` y `nsubj:pass`.
- **Objetos**: Identificando `obj` como receptor directo.
- **Estructuras Preposicionales**: Analizando el arco `obl` y su correspondiente `case` (preposición).

3.3. Uso de Enhanced++ Dependencies

Se ha configurado CoreNLP para devolver dependencias mejoradas. A diferencia de las dependencias básicas, estas resuelven fenómenos como la elisión de sujetos en conjunciones (coordinadas) y las relaciones de control. Esto permite que en oraciones como *"Sherlock saw the case and solved it"*, el sistema sea capaz de extraer dos proposiciones completas compartiendo el mismo sujeto, aumentando drásticamente la precisión del análisis literario.

3.4. Jerarquía de Exclusión de Patrones

1. Intenta extraer la estructura más rica (`NVNPN`).
2. Si no existe, intenta extraer la transitiva (`NVN`).
3. Como último recurso, emite la base (`NV`).

4. Tratamiento Avanzado y Mejoras Semánticas

4.1. Normalización de la Voz Pasiva (Punto Extra)

Nuestro sistema utiliza el arco `nsubj:pass` para detectar el sujeto receptor y el arco `obl:agent` para localizar al autor real de la acción.

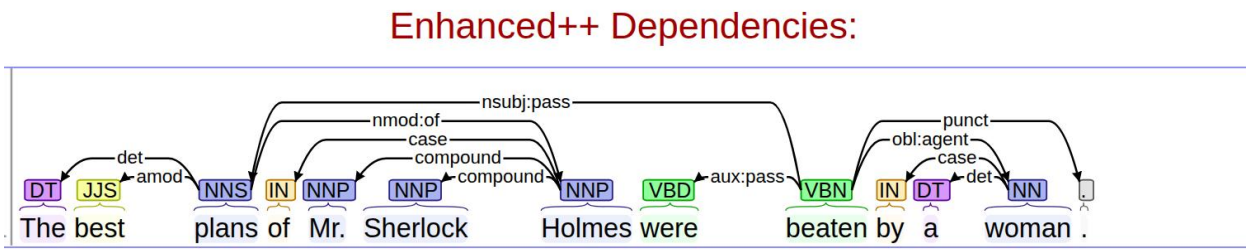

Figura 2: Recuperación semántica del agente real en voz pasiva.

4.2. Unificación de Entidades y Personajes (NER)

Para que las estadísticas de estilo sean coherentes, el sistema sustituye nombres propios ("Sherlock") y pronombres ("He") por la categoría común `PERSON`.

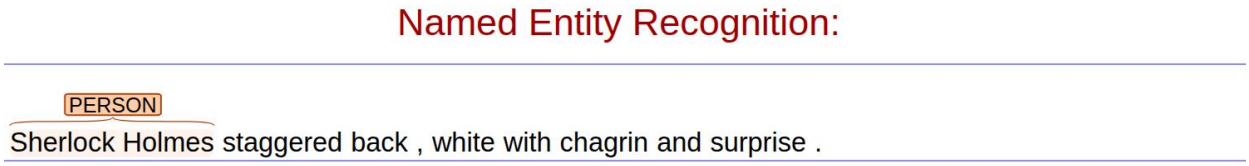

Figura 3: Unificación de participantes bajo la categoría común PERSON mediante NER.

4.3. Detección Multidimensional: POS y NER

A continuación se visualiza la complejidad de las etiquetas que el sistema procesa simultáneamente para lograr una extracción limpia y estructurada.

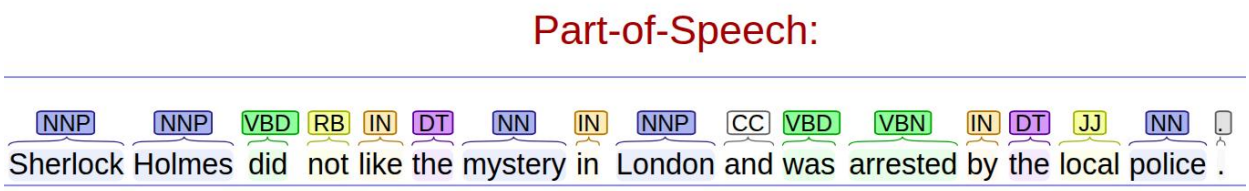

Figura 4: Capa de etiquetado POS y NER sobre la que opera el extractor.

4.4. Gestión de Phrasal Verbs

Mediante la relación `compound:prt`, el sistema une el verbo con su partícula semántica (ej: *look up*), preservando el sentido completo de la proposición.

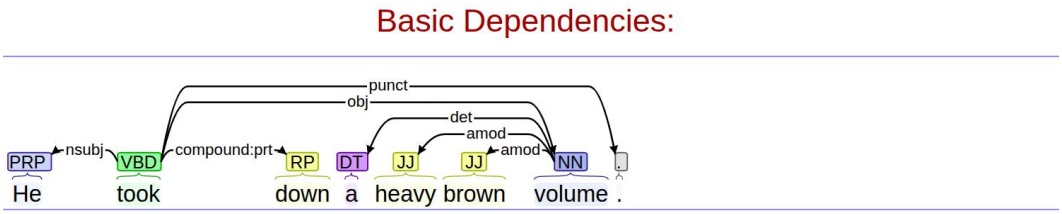

Figura 5: Identificación de Phrasal Verbs: Fusión del verbo con su partícula.

5. Análisis de Resultados en el Corpus

Se han analizado los 12 relatos de *The Adventures of Sherlock Holmes*, procesando un total de **8.785 proposiciones únicas**.

5.1. Impacto de la Unificación NER en el Ranking

Sin la unificación, el ranking estaría dominado por pronombres genéricos. Al aplicar el módulo NER, las acciones de los protagonistas se consolidan, permitiendo un análisis real del estilo narrativo.

Proposición	**Tipo**	**Frecuencia**
PERSON, say	NV	216
PERSON, think	NV	138
PERSON, see	NV	132
PERSON, know	NV	116
PERSON, be	NV	109
PERSON, have	NV	96
PERSON, go	NV	76
PERSON, tell, PERSON	NVN	47

Tabla 1: Principales proposiciones tras el proceso de normalización estructural y NER.

6. Traza de Procesamiento Algorítmico

Desglosamos el proceso de la frase: *Ï told you that it would call."*

1. **Tokenización y Parsing**: Se asigna el rol `nsubj` a Ïƶ `obj` a ƶou".
2. **Identificación NER**: Se detecta que ambos son humanos (`PERSON`).
3. **Lematización**: "told"se reduce a "tell".
4. **Extracción**: Se genera la proposición unificada.

7. Problemas Encontrados y Soluciones

1. **Saturación de RAM**: CoreNLP es intensivo en recursos. Se solucionó mediante un sistema de *batching* en el script.
2. **Ambigüedad de Pronombres**: El uso de pronombres dispersaba los resultados. Se resolvió mediante la sustitución forzada bajo la categoría NER.

8. Manual de Ejecución e Instalación

```
# 1. Iniciar servidor (Instrucci n docente: 3GB RAM)
java -mx3g -cp "*" edu.stanford.nlp.pipeline.StanfordCoreNLPServer
   -port 9005

# 2. Procesar libro completo
./practica2.py sherlock.txt output.json --ner
```

9. Trabajo Futuro y Evolución

Una extensión natural sería la integración de la resolución de correferencia profunda. Esto permitiría unificar el conocimiento a nivel de párrafo entero, creando grafos de relación mucho más densos y fieles a la narrativa.

10. Conclusiones Finales

El desarrollo de esta práctica ha permitido validar que el análisis de dependencias mejoradas es la herramienta más eficaz para extraer conocimiento semántico. La normalización de la pasiva y la unificación han sido claves en el proceso.

A. Muestreo Detallado de Salida JSON


```
{
  "PERSON, tell, PERSON": {
    "sentences": [
      "I told you that I would call .",
      "She showed me , as I told you she would ."
    ],
    "type": "NVN",
    "count": 47,
    "sbj": "PERSON",
    "vrb": "tell",
    "obj": "PERSON"
  }
}
```


B. Mapeo de Etiquetas POS Utilizadas

Etiqueta	**Significado**
VB	Verbo (forma base)
VBD	Verbo (pasado)
VBN	Verbo (participio pasado)
VBZ	Verbo (3ª pers. singular presente)
NN	Sustantivo común
NNP	Nombre propio
PRP	Pronombre personal

Tabla 2: Principales categorías léxicas utilizadas para el análisis estructural.

C. Glosario Lingüístico y Referencias

C.1. Glosario

- **Lematización**: Reducción a la raíz canónica.
- **NER**: Reconocimiento de Entidades Nombradas.
- **Universal Dependencies**: Marco de trabajo sintáctico internacional.

C.2. Referencias Bibliográficas

- Manning, C. et al. (2014). *The Stanford CoreNLP Natural Language Processing Toolkit.*
- Nivre, J. et al. (2020). *Universal Dependencies v2: An Evergrowing collection.*
- Doyle, A. C. (1892). *The Adventures of Sherlock Holmes.* Project Gutenberg.